

数理最適化 × 機械学習を用いたダイナミックプライシング

中川海智

June 11, 2025

兵庫県立大学

背景：

- 数理最適化ソルバーの進化により、機械学習（ML）と数理最適化（MO）の融合、いわゆる **MOAI** の研究が活発化

本プロジェクトの位置づけ：

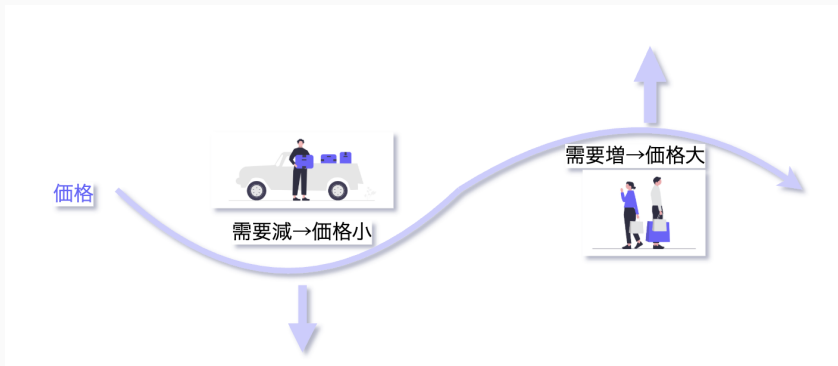
- MOAI の中でも、**ML → MO** の流れに着目
- 機械学習により需要などを予測し、その結果をもとに価格最適化を実行

目的：

- **Gurobi** を活用し、**ML → MO の統合プロセス**が手軽に実現できることを示す
- 実務的な価格戦略問題における **MOAI** の実用性 を提示する

ダイナミックプライシングとは？

- 商品やサービスの価格を需要・供給・時期・在庫状況などに応じてリアルタイムに変化させる戦略
- 目的：利益最大化、在庫調整、顧客セグメンテーション



大ナミックプライシングとは？

- 経験や勘に基づく価格設定から、データドリブンな意思決定へ。
- ML で需要予測 → Gurobi で価格最適化
- 売上最大化・現実的な価格制約を同時に満たす

- **Amazon**：過去の購買履歴や需要予測に基づき価格を動的変更
- **Uber**：サージプライシングにより需要ピーク時に価格上昇
- **航空会社**：搭乗日や残席数に応じて価格変動

- Python, pandas, scikit-learn, Gurobi 10.0, gurobi-machinelearning
- モデル：重回帰分析 (R^2 : 0.294)
- ソルバー：非線形連続最適化 (非凸)

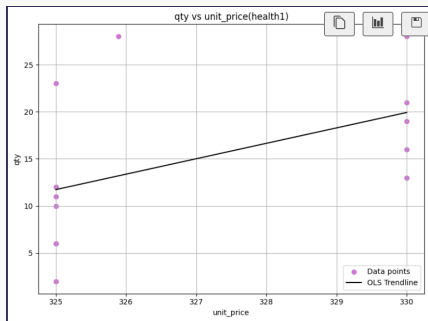
データの概要

- サンプル数: 676 件、特徴量: 30 項目
- 商品 ID、月別販売数量、価格、送料、競合価格など
- 欠損値なし、カテゴリ・時系列・数値混合データ

	product_id	product_category_name	month_year	qty	total_price	freight_price	unit_price
0	bed1	bed_bath_table	01-05-2017	1	45.95	15.100000	45.950000
1	bed1	bed_bath_table	01-06-2017	3	137.85	12.933333	45.950000
2	bed1	bed_bath_table	01-07-2017	6	275.70	14.840000	45.950000
3	bed1	bed_bath_table	01-08-2017	4	183.80	14.287500	45.950000
4	bed1	bed_bath_table	01-09-2017	2	91.90	15.100000	45.950000
5	bed1	bed_bath_table	01-10-2017	3	137.85	15.100000	45.950000
6	bed1	bed_bath_table	01-11-2017	11	445.85	15.832727	40.531818
7	bed1	bed_bath_table	01-12-2017	6	239.94	15.230000	39.990000
8	bed1	bed_bath_table	01-01-2018	19	759.81	16.533684	39.990000
9	bed1	bed_bath_table	01-02-2018	18	719.82	13.749444	39.990000

10 rows × 30 columns

単価と売上数量の関係



横軸に単価、縦軸に売上数量をプロットした図

商品 health5 の例

単価を変更すると売上数量も変動

→

これは価格が需要に影響を与えている

最適化問題：
単価 × 売上数量 を最大化

最終目標：

単価 \times 売上数量 を最大化する単価を決定する

今後のステップ：

1. 単価などの特徴量から売上数量を予測する機械学習モデル $f(x)$ を構築
2. $f(x)$ によって予測された売上数量 \times 単価 = (利益) を最大化する最適化問題を定式化

最終目標：

単価 \times 売上数量 を最大化する単価を決定する

今後のステップ：

1. 単価などの特徴量から売上数量を予測する機械学習モデル $f(x)$ を構築
2. $f(x)$ によって予測された売上数量 \times 単価 = (利益) を最大化する最適化問題を定式化

- 目的：年、月ごとの売上数量（需要）を予測する
- モデル：重回帰分析（**Linear Regression**）
- 備考：相関の高い特徴量間（特に価格と相関が高い）などは除去済み
- 詳細は同フォルダの `.ipynb` ファイルを参照

特徴量（説明変数）

- 使用した主な特徴量：
 - 商品単（ unit_{price} ）曜日情報（週末・平日）

			unit_price_x	customers_y	weekend	weekday
year	month	product_id				
2017	1	health5	349.900000	1775.0	9.0	6.0
		health7	64.990000	1775.0	9.0	6.0
	2	bed2	89.900000	968.0	8.0	2.0
		computers4	159.990000	968.0	8.0	2.0
		cool1	85.704286	551.0	8.0	2.0
...
2018	8	watches2	138.000000	1343.0	8.0	2.0
		watches3	77.821429	1295.0	8.0	2.0
		watches4	105.000000	1152.0	8.0	2.0
		watches6	112.000000	1284.0	8.0	2.0
		watches8	157.945455	1060.0	8.0	2.0

■ 676 rows x 4 columns

目的変数（予測ターゲット）

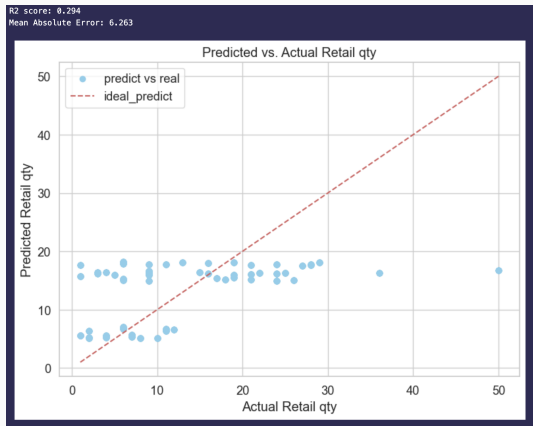
- 目的変数：売上数量（**qty**）
- 顧客数、価格、競合分析の影響を受ける

			qty
year	month	product_id	
2017	1	health5	160
		health7	20
	2	bed2	38
		computers4	54
		cool1	105
...
2018	8	watches2	45
		watches3	420
		watches4	70
		watches6	14
		watches8	110

676 rows x 4 columns

予測結果（予測値 vs 実測値）

- $R^2 = 0.294$, MAE = 6.263
- 単純モデルながらも一定の予測精度あり



最終目標：

単価 × 売上数量 を最大化する単価を決定する

今後のステップ：

1. 単価などの特徴量から売上数量を予測する機械学習モデル $f(x)$ を構築
2. $f(x)$ によって予測された売上数量 × 単価 = (利益) を最大化する最適化問題を定式化

最適化モデルの定式化

定式化

入力

月:m, 商品:p, モデル:f, S: 在庫量, F: 商品 p の価格を含めた特徴量, 変更前価格: x_{berore}

変数

変更後価格:x, 売上量:q

定式化 (自然言語 ver)

$$\text{maximize. } \sum (\text{各月の売上} \times \text{各月の価格}) \quad (1)$$

$$\text{subject to.} \quad (2)$$

$$\text{各商品の売上モデル(価格を含む商品の特徴量)} = \text{売上量} \quad (3)$$

$$\text{在庫量} = \sum \text{売上量} \quad (4)$$

$$\text{変更後価格} \in \text{価格を含む商品の特徴量} \quad (5) \quad 15$$

定式化

$$\text{maximize. } \sum_{m=1}^{12} q_m * x_m \quad (1)$$

$$\text{subject to.} \quad (2)$$

$$f(F_m) = q_m \quad (m = 1, 2, \dots, 12) \quad (3)$$

$$S = \sum_{m=1}^{12} q_i \quad (4)$$

$$x_m \in F_m \quad (5)$$

最適化モデルの定式化

このままではソルバーに投げても価格が非現実的な解を出力したため制約式 (6) を追加した下記のような定式化にする

定式化 (**solver.ver**)

$$\text{maximize. } \sum_{m=1}^{12} q_m * x_m \quad (1)$$

$$\text{subject to.} \quad (2)$$

$$f(F_m) = q_m \quad (m = 1, 2, \dots, 12) \quad (3)$$

$$S = \sum_{m=1}^{12} q_i \quad (4)$$

$$x_m \in F_m \quad (5)$$

$$0.8x_{before} \leq x \leq 1.2x_{before} \quad (6) \quad 17$$

注意：本結果は一つの商品のみの結果だけ可視化している。
在庫量の個数制約と最適化後の利益変化




図 1: 在庫量と売上量




図 2: 最適化前後の売上高 (目的関数値)

最適後の単価と売上量



図 3: 最適化前後の単価




図 4: 最適化前後の売上量

本研究の成果：

- 重回帰分析に基づき、すべての制約条件を満たしつつ売上向上を実現
- 単価に制約を設けることで、現実的な価格設定が可能に

課題と改善点：

- データ数が少なく、モデルの汎化に限界
- 価格・売上数量を連続値で扱う → 整数制約が現実的
- 競合の戦略、人の感情（価格感度）を考慮できていない

今後の展望：

- 動的価格最適化：時間とともに変化する価格・需要に対応
- 消費者の心理・行動要因を取り入れたモデル構築
- 機械学習と数理最適化の融合による意思決定支援の高度化

- Pierre Bonami, *Using Trained Machine Learning Predictors in Gurobi*, Gurobi Optimization, LLC (2023).
<https://github.com/Gurobi/gurobi-machinelearning>
- Gurobi Optimization, *Slides: Using Trained ML Predictors in Gurobi*, (2023).
<https://cdn.gurobi.com/wp-content/uploads/Using-Trained-Machine-Learning-Predictors-in-Gurobi-slides.pdf>
- NearMe Tech, *Gurobi \propto Machine Learning* 第二弾：機械学習と数理最適化の統合, (2024).
https://speakerdeck.com/nearme_tech/gurobi-machine-learning-2-ji-jie-xue-xi-toshu-li-zui-shi-hua-notong-he
- MOAI Lab, 「機械学習 \propto 数理最適化 (MOAI)」の実務的アプローチ, note, (2024).
https://note.com/moai_lab/n/nb28898e99919
- Siddharshan, *Retail Price Optimization Dataset*, Kaggle, (2021).
<https://www.kaggle.com/datasets/siddharshan/retail-price-optimization/data>